به نام خدا

گزارش پروژه کارگاه هوش مصنوعی چندوجهی

عنوان: تشخیص عنوان فارسی کتاب از تصویر جلد با مدل Qwen2.5-VL و فاین‌تیون QLoRA

ارائه‌دهنده : فائزه علیمیرزایی

مقدمه

هدف این پروژه استخراج خودکار عنوان فارسی کتاب از تصویر جلد با استفاده از مدل‌های چندوجهی است. برای این منظور، مدل Qwen2.5-VL-3B-Instruct ابتدا بدون آموزش تکمیلی روی ۲۰۰ نمونه آزمون ارزیابی شد. سپس مدل با روش QLoRA روی ۱۰۰۰ نمونه آموزشی فاین‌تیون و دوباره روی همان مجموعه آزمون ارزیابی شد.

خواندن عنوان کتاب به‌دلیل تنوع فونت، اندازه، محل نوشته و وجود متن‌های دیگری مانند نام نویسنده، مترجم، ناشر و نوبت چاپ دشوار است. نتایج نشان داد فاین‌تیون باعث بهبود هر چهار معیار ارزیابی شد؛ بااین‌حال، تشخیص عناوین چندخطی و جداسازی عنوان از سایر نوشته‌های جلد همچنان مهم‌ترین منابع خطا هستند.

آماده سازی محیط اجرا

آزمایش‌ها در محیط Kaggle و با GPU مدل Tesla T4 دارای ۱۴٫۵۶ گیگابایت حافظه انجام شدند. نسخه Python برابر 3.12.13 و نسخه PyTorch برابر 2.10.0+cu128 بود. برای جلوگیری از ناسازگاری کتابخانه‌ها، نسخه‌های Transformers 4.57.1 ، Hugging Face Hub 0.36.0، BitsAndBytes 0.50.2، Accelerate 1.13.0، PEFT 0.19.1 و qwen-vl-utils 0.0.14 به‌صورت ثابت نصب شدند. دسترسی CUDA نیز پیش از اجرای مدل بررسی و تأیید شد.

بررسی اولیه دیتاست

دیتاست shenasa/bookroom-persian-book-covers-and-titles ابتدا به‌صورت streaming بارگذاری شد تا بدون دانلود کامل داده‌ها، ساختار آن بررسی شود. دیتاست شامل دو ستون image و text است که به‌ترتیب تصویر جلد و عنوان فارسی کتاب را نگه می‌دارند.

برای اطمینان از درست بودن روش بارگذاری، پنج نمونه‌ی اول بخش train نمایش داده شدند. تصاویر و عنوان‌های فارسی بدون خطای decode قابل مشاهده بودند. جزئیات این نمونه‌ها در Notebook وجود دارد و در گزارش فقط نتیجه‌ی کلی بررسی ثبت می‌شود.

همچنین مشخص شد تصاویر ابعاد یکسانی ندارند. بنابراین هنگام آماده‌سازی ورودی مدل باید نسبت طول به عرض تصاویر حفظ شود تا نوشته‌های روی جلد کشیده یا فشرده نشوند.

آماده‌سازی داده‌های آموزش و آزمون

مطابق صورت پروژه، ۱۰۰۰ نمونه سالم برای آموزش و ۲۰۰ نمونه برای آزمون در نظر گرفته شد. چون دیتاست به‌صورت Streaming بارگذاری شده بود، نمونه‌ها به‌ترتیب پیمایش شدند و سلامت تصویر و وجود عنوان متنی برای هر نمونه بررسی شد. در صورتی که یک تصویر قابل خواندن نبود، قرار بود آن نمونه حذف و نمونه سالم بعدی جایگزین آن شود.

در بررسی انجام‌شده، هر ۱۰۰۰ نمونه آموزشی و ۲۰۰ نمونه آزمون بدون خطا بارگذاری شدند؛ بنابراین در این اجرا نیازی به جایگزینی نمونه‌ها نبود. برای هر نمونه، علاوه بر تصویر و عنوان کتاب، شماره اصلی آن

در دیتاست نیز با نام source_index ذخیره شد. این کار باعث می‌شود مجموعه‌های آموزش و آزمون در اجراهای بعدی قابل بازتولید باشند.

فهرست شماره نمونه‌های انتخاب‌شده در یک فایل JSON ذخیره شد. در اولین تلاش، ستون‌های دیتاست مستقیماً قابل ذخیره‌سازی در قالب JSON نبودند و خطای Serialization ایجاد شد. علت این بود که خروجی ستون‌ها از نوع اختصاصی Column بود. با تبدیل این ستون‌ها به فهرست معمولی پایتون، فایل Manifest با موفقیت ذخیره و دوباره بارگذاری شد.

انتخاب مدل پایه

برای این پروژه به مدلی نیاز بود که علاوه بر دریافت تصویر، توانایی تشخیص نوشته‌های موجود روی جلد و تولید متن فارسی را داشته باشد. همچنین اندازه مدل باید به‌اندازه‌ای محدود می‌بود که امکان بارگذاری و فاین‌تیون آن روی GPU مدل Tesla T4 در Kaggle وجود داشته باشد.

چند گزینه از نظر اندازه، پشتیبانی از ورودی تصویری و امکان فاین‌تیون بررسی شدند. در نهایت مدل Qwen2.5-VL-3B-Instruct انتخاب شد. این مدل با حدود سه میلیارد پارامتر، تعادل مناسبی میان توانایی پردازش تصویر، خواندن متن و محدودیت منابع سخت‌افزاری ایجاد می‌کند.

روش فاین‌تیون و تنظیمات آموزش

مدل پایه به‌صورت ۴ بیتی و با روش NF4 همراه با Double Quantization بارگذاری شد. نوع محاسبات داخلی مدل float16 در نظر گرفته شد. برای حفظ جزئیات نوشته‌های روی جلد، حداکثر وضوح ورودی پردازشگر برابر با 28 × 28 × 768 تنظیم شد.

برای آموزش از روش QLoRA استفاده شد. آداپتورهای LoRA روی تمام لایه‌های خطی مدل اعمال شدند. مقدار رتبه LoRA برابر ۱۶، ضریب Alpha برابر ۳۲ و Dropout برابر ۰٫۰۵ بود. در مجموع ۴۱,۳۶۳,۴۵۶ پارامتر، معادل ۱٫۰۸۹۷ درصد از کل پارامترهای مدل، قابل‌آموزش بودند.

آموزش روی ۱۰۰۰ نمونه، به‌مدت دو دوره و با اندازه Batch برابر ۱ انجام شد. مقدار Gradient Accumulation برابر ۸، نرخ یادگیری اولیه برابر 1e-4 و زمان‌بند نرخ یادگیری از نوع Cosine بود.

بهینه‌ساز paged_adamw_8bit و Gradient Checkpointing نیز برای کاهش مصرف حافظه استفاده شدند. مقدار Seed برابر ۴۲ در نظر گرفته شد.

آماده‌سازی و بارگذاری مدل در Kaggle

مدل Qwen2.5-VL-3B-Instruct با موفقیت به‌صورت ۴ بیتی روی GPU بارگذاری شد. برای آموزش و ارزیابی از یک پرامپت مشترک استفاده شد تا مقایسه مدل پایه و مدل فاین‌تیون‌شده منصفانه باشد. پرامپت از مدل می‌خواست عنوان اصلی و زیرعنوان مرتبط را به‌ترتیب خطوط جلد استخراج کند و نام نویسنده، مترجم، ناشر و عبارت‌های مربوط به نوبت چاپ را حذف کند. همچنین ترجمه، اصلاح یا حدس‌زدن متن ممنوع شد.

تولید متن در هر دو ارزیابی به‌صورت قطعی و بدون Sampling انجام شد و حداکثر طول خروجی ۶۴ توکن بود.

ارزیابی کامل مدل پایه روی مجموعه آزمون

مدل پایه Qwen2.5-VL-3B-Instruct بدون فاین‌تیون روی تمام ۲۰۰ نمونه مجموعه test_200 ارزیابی شد. برای جلوگیری از تأثیر تصادفی فرایند تولید، تولید متن به‌صورت قطعی و با غیرفعال‌کردن Samplingانجام شد. حداکثر طول خروجی نیز ۶۴ توکن در نظر گرفته شد.

در این مرحله از مدل خواسته شد عنوان کامل کتاب را از روی جلد استخراج کند، عنوان اصلی و زیرعنوان مرتبط را به ترتیب خطوط ترکیب کند و نوشته‌هایی مانند نام نویسنده، مترجم، ناشر و نوبت چاپ را در خروجی نیاورد. ترجمه، اصلاح یا حدس‌زدن متن نیز در پرامپت ممنوع شد. همین پرامپت و تنظیمات در ارزیابی مدل فاین‌تیون‌شده نیز استفاده شدند تا مقایسه منصفانه باشد.

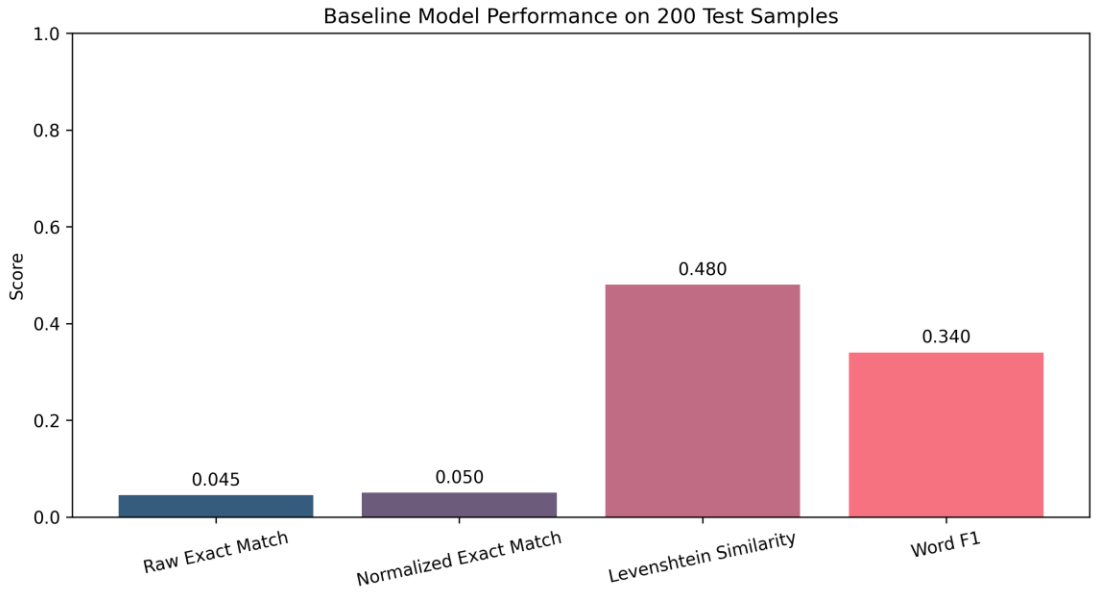
چهار معیار زیر برای ارزیابی در نظر گرفته شدند:

- Raw Exact Match: تطابق کاملاً یکسان پیش‌بینی و عنوان مرجع
- Normalized Exact Match: تطابق کامل پس از یکسان‌سازی حروف فارسی و فاصله‌ها
- Levenshtein Similarity: میزان شباهت نویسه‌ای پیش‌بینی و عنوان مرجع

- Word F1: میزان هم‌پوشانی کلمات پیش‌بینی با عنوان مرجع

مدل پایه در ۹ نمونه از ۲۰۰ نمونه، معادل ۴٫۵ درصد، به تطابق خام کامل رسید. پس از نرمال‌سازی متن، ۱۰ نمونه معادل ۵ درصد کاملاً صحیح بودند. مقدار Levenshtein Similarity برابر ۰٫۴۸۰ و Word F1 برابر ۰٫۳۴۰ به دست آمد.

این نتایج نشان داد مدل پایه در بسیاری از تصاویر قادر به شناسایی بخشی از عنوان است، اما اختلاف‌های کوچک املایی، ترتیب نادرست خطوط، حذف زیرعنوان یا اضافه‌کردن نوشته‌های دیگر جلد باعث کاهش Exact Match می‌شوند. به همین دلیل، تفسیر Exact Match در کنار معیارهای جزئی‌تر ضروری است.



شکل ۱ ـ عملکرد مدل پایه روی ۲۰۰ نمونه مجموعه آزمون

آماده‌سازی داده‌ها برای فاین‌تیون

برای فاین‌تیون از ۱۰۰۰ نمونه مجموعه train_1000 استفاده شد. هر نمونه شامل تصویر جلد به‌عنوان ورودی و عنوان مرجع به‌عنوان پاسخ مورد انتظار بود. مجموعه test_200 در فرایند آموزش استفاده نشد و فقط برای ارزیابی مدل پایه و مدل فاین‌تیون‌شده نگه داشته شد.

برای هر نمونه، یک مکالمه شامل تصویر جلد، پرامپت استخراج عنوان و پاسخ صحیح ساخته شد. توکن‌های مربوط به تصویر و دستور کاربر در محاسبه Loss نادیده گرفته شدند و فقط توکن‌های پاسخ

دستیار، یعنی عنوان مرجع، تحت نظارت قرار گرفتند. توکن‌های Padding نیز با مقدار 100- از محاسبه Loss حذف شدند.

پیش از شروع آموزش، یک Batch آزمایشی ساخته شد. شکل ورودی و برچسب‌ها صحیح بود و تعداد توکن‌های تحت نظارت برای نمونه‌ها بررسی شد. سپس یک Smoke Test روی مدل انجام گرفت. مقدار Loss این آزمایش برابر ۲٫۰۳۲ و متناهی بود؛ بنابراین صحت آماده‌سازی داده، برچسب‌ها و مسیر محاسبه Loss تأیید شد.

فاین‌تیون مدل با روش QLoRA

به‌دلیل محدودیت حافظه GPU در Kaggle ، مدل با روش QLoRA فاین‌تیون شد. مدل پایه با کوانتیزه‌سازی ۴ بیتی NF4 و Double Quantization بارگذاری شد و نوع محاسبات داخلی برابر float16 در نظر گرفته شد. این روش امکان آموزش آداپتورهای LoRA را بدون تغییر مستقیم تمام پارامترهای مدل فراهم می‌کند.

آداپتورهای LoRA روی تمام لایه‌های خطی مدل اعمال شدند. تنظیمات اصلی آن‌ها به شرح زیر بود:

- رتبه LoRA برابر ۱۶
- مقدار LoRA Alpha برابر ۳۲
- مقدار LoRA Dropout برابر ۰٫۰۵
- BiasبرابرNone
- لایه‌های هدف برابر تمام لایه‌های خطی

در مجموع ۴۱,۳۶۳,۴۵۶ پارامتر از ۳,۷۹۵,۹۸۶,۴۳۲ پارامتر مدل قابل‌آموزش بودند. بنابراین تنها ۱٫۰۸۹۷ درصد پارامترهای مدل در فرایند فاین‌تیون تغییر کردند. تنظیمات آموزش به صورت زیر بودند:

- تعداد نمونه‌های آموزشی: ۱۰۰۰
- تعداد دوره‌های آموزش: ۲
- اندازه Batch: برابر ۱
- Gradient Accumulation: برابر ۸
- نرخ یادگیری اولیه: 1e-4

- زمان‌بند نرخ یادگیری: Cosine
- بهینه‌ساز: paged_adamw_8bit
- Warmup Ratio: برابر ۰٫۰۵
- حداکثر Gradient Norm: برابر ۰٫۳
- دقت محاسبات: FP16
- Seed: برابر ۴۲
- تعداد گام‌های بهینه‌سازی: ۲۵۰

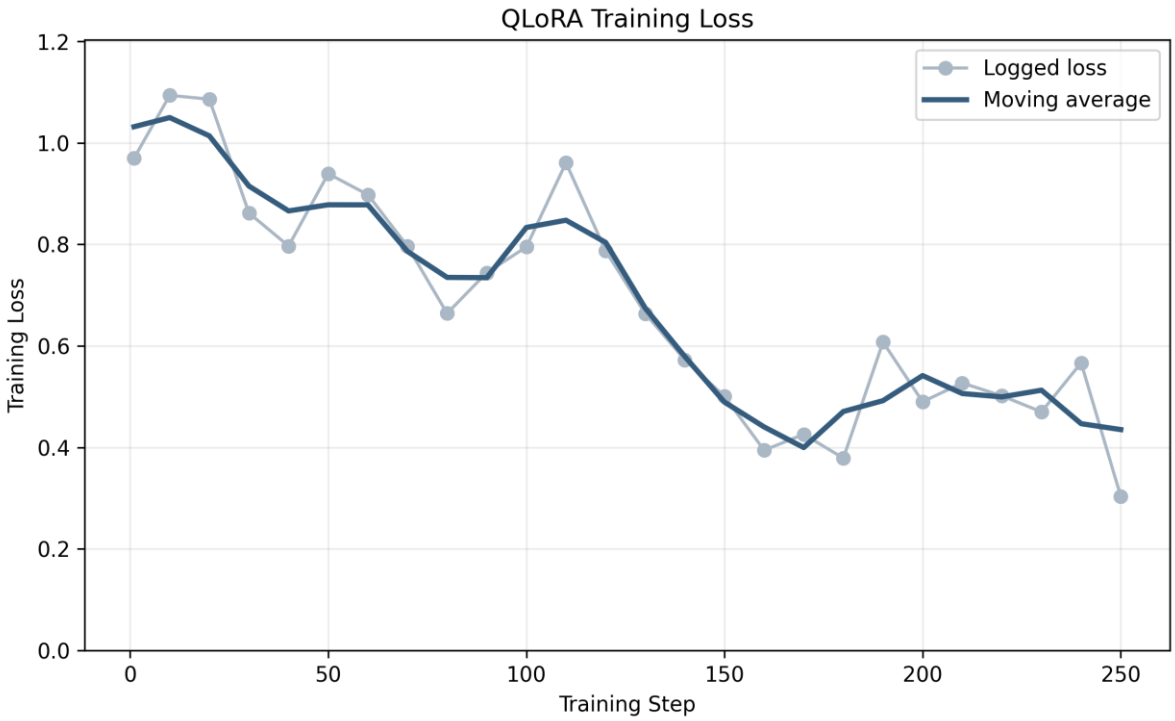
Gradient Checkpointing برای کاهش مصرف حافظه فعال شد. همچنین هر ۱۰ گام یک Checkpoint ذخیره شد تا در صورت قطع نشست Kaggle امکان ادامه آموزش وجود داشته باشد.

در این آزمایش از مجموعه اعتبارسنجی و Early Stopping استفاده نشد و آموزش برای دو دوره ثابت ادامه یافت. Data Augmentation نیز اعمال نشد.

نتایج آموزش

آموزش در ۲۵۰ گام و دو دوره کامل انجام شد. زمان کل آموزش برابر ۷۲۰۵ ثانیه، معادل حدود دو ساعت، بود. بیشترین حافظه تخصیص‌یافته GPU در طول آموزش ۴٫۷۱ گیگابایت ثبت شد.

میانگین Loss گزارش‌شده برای کل آموزش برابر ۰٫۶۷۳ بود. آخرین Loss ثبت‌شده در گام ۲۵۰ نیز برابر ۰٫۳۰۴ به دست آمد. اگرچه مقدار Loss بین Batch های مختلف نوسان داشت، روند میانگین متحرک آن در طول آموزش نزولی بود. این روند نشان می‌دهد فرایند بهینه‌سازی به‌درستی انجام شده و مدل الگوهای موجود در داده‌های آموزشی را یاد گرفته است.



شکل ۲ ـ تغییرات Loss در طول ۲۵۰ گام فاین‌تیون QLoRA

ارزیابی مدل بعد از فاین‌تیون

پس از پایان آموزش، آداپتور نهایی LoRA فعال و مدل فاین‌تیون‌شده روی همان ۲۰۰ نمونه مجموعه test_200 ارزیابی شد. پرامپت، پردازش تصاویر، حداکثر طول خروجی و تنظیمات تولید متن دقیقاً با ارزیابی مدل پایه یکسان بودند.

مدل فاین‌تیون‌شده در ۲۸ نمونه به Raw Exact Match رسید. تعداد تطابق‌های کامل نرمال‌شده نیز ۲۸ نمونه بود. بنابراین Raw Exact Match و Normalized Exact Match هر دو به ۱۴ درصد رسیدند. مقدار Levenshtein Similarity برابر ۰٫۶۰۲ و Word F1 برابر ۰٫۴۴۶ به دست آمد.

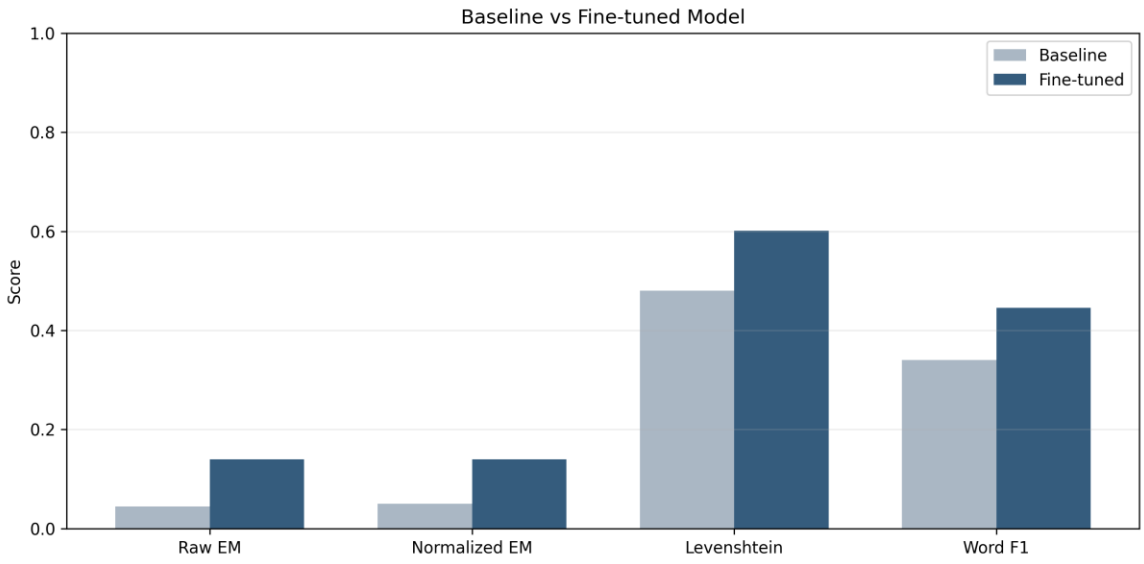
مقایسه نتایج قبل و بعد از فاین‌تیون

معیار	مدل پایه	مدل فاین تیون شده	تغییر
Raw Exact Match	۰٫۰۴۵	۰٫۱۴۰	+۰٫۰۹۵
Normalized Exact Match	۰٫۰۵۰	۰٫۱۴۰	+۰٫۰۹۰
Levenshtein Similarity	۰٫۴۸۰	۰٫۶۰۲	+۰٫۱۲۲
Word F1	۰٫۳۴۰	۰٫۴۴۶	+۰٫۱۰۵

جدول ۱ ـ مقایسه عملکرد مدل پایه و مدل فاین‌تیون‌شده

تعداد پیش‌بینی‌های کاملاً صحیح خام از ۹ به ۲۸ نمونه افزایش یافت؛ بنابراین مدل فاین‌تیون‌شده ۱۹ عنوان صحیح بیشتر از مدل پایه تولید کرد. تعداد تطابق‌های کامل نرمال‌شده نیز از ۱۰ به ۲۸ نمونه رسید.

افزایش Levenshtein Similarity نشان می‌دهد خروجی‌های مدل فاین‌تیون‌شده از نظر ترتیب و محتوای نویسه‌ها به عناوین مرجع نزدیک‌تر شده‌اند. افزایش Word F1 نیز نشان می‌دهد تعداد کلمات مشترک میان پیش‌بینی و عنوان مرجع بیشتر شده است. بنابراین بهبود مدل فقط به Exact Match محدود نبوده و در شباهت جزئی متن نیز مشاهده می‌شود.



شکل ۳ ـ مقایسه معیارهای مدل پایه و مدل فاین‌تیون‌شده روی ۲۰۰ نمونه آزمون

تحلیل نمونه‌های بهبودیافته و تضعیف‌شده

برای بررسی دقیق‌تر اثر فاین‌تیون، تغییر Levenshtein Similarity برای هر یک از ۲۰۰ نمونه محاسبه شد. نتیجه این بررسی به صورت زیر بود:

- ۱۳۱ نمونه بهبود یافتند.
- ۲۸ نمونه بدون تغییر باقی ماندند.
- ۴۱ نمونه تضعیف شدند.

بهبود ۱۳۱ نمونه نشان می‌دهد فاین‌تیون در بیشتر تصاویر باعث نزدیک‌ترشدن خروجی مدل به عنوان مرجع شده است. بااین‌حال، بهبود در همه نمونه‌ها یکنواخت نبود.

یکی از خطاهای رایج، اضافه‌کردن نام نویسنده، ناشر یا شماره جلد به خروجی بود. برای مثال، در نمونه ۱۶۳ مدل پایه عنوان «ظفرنامه» را کاملاً صحیح تشخیص داده بود، اما مدل فاین‌تیون‌شده عبارت «ظفر نامه (نشر مولی)» را تولید کرد. در نمونه ۱۴۱ نیز نام نویسنده به عنوان اصلی اضافه شد. این موارد نشان می‌دهند مدل هنوز در تفکیک نقش نوشته‌های مختلف روی جلد مشکل دارد.

خطاهای دیگر شامل تشخیص نادرست فونت‌های پیچیده، جابه‌جایی ترتیب عنوان و زیرعنوان، تبدیل حروف فارسی و عربی و تولید عبارت‌هایی بود که بخشی از عنوان مرجع نبودند. عناوین طولانی یا چندخطی نیز معمولاً دشوارتر از عناوین کوتاه بودند.

محدودیت‌های ارزیابی

Exact Match معیار سخت‌گیرانه‌ای است و هر اختلاف کوچک در فاصله‌گذاری، نیم‌فاصله، نشانه‌گذاری یا شکل حروف باعث صفر شدن آن می‌شود. به همین دلیل، Normalized Exact Match، Levenshtein Similarity و Word F1 نیز در کنار آن گزارش شدند.

بررسی خطاها نشان داد برخی عناوین مرجع شامل عباراتی هستند که به‌وضوح روی تصویر جلد مشاهده نمی‌شوند. در چنین نمونه‌هایی ممکن است مدل متن قابل‌مشاهده روی جلد را درست استخراج کند، اما به‌دلیل تفاوت با عنوان ثبت‌شده در دیتاست امتیاز کامل نگیرد. بنابراین بخشی از خطاهای ثبت‌شده می‌تواند ناشی از ناسازگاری میان تصویر و برچسب مرجع باشد.

این آزمایش فقط با ۱۰۰۰ نمونه آموزشی، دو دوره آموزش و یک مقدار Seed انجام شد. نبود مجموعه اعتبارسنجی مستقل نیز امکان استفاده از Early Stopping و انتخاب بهترین Checkpoint بر اساس Validation Loss را محدود کرد.

ذخیره خروجی‌های نهایی

پس از پایان آزمایش، نتایج مدل پایه و مدل فاین‌تیون‌شده برای هر ۲۰۰ نمونه در فایل‌های CSV ذخیره شدند. تاریخچهLoss ، جدول مقایسه معیارها، نمونه‌های دارای بیشترین افت، خلاصه نتایج و سه نمودار نیز ذخیره شدند.

آداپتور نهایی مدل همراه با تنظیمات LoRA ، پردازشگر تصویرTokenizer در فایل final_adapter_v2.zip ذخیره شد. این فایل حدود ۱۵۰ مگابایت حجم دارد و سلامت محتوای آن پس از دانلود بررسی شد.

نتیجه‌گیری

در این پروژه مدل Qwen2.5-VL-3B-Instruct برای استخراج عنوان فارسی کتاب از تصویر جلد انتخاب و با روش QLoRA روی ۱۰۰۰ نمونه فاین‌تیون شد. مدل پایه و مدل فاین‌تیون‌شده در شرایط یکسان روی ۲۰۰ نمونه آزمون ارزیابی شدند.

Raw Exact Match از ۴٫۵ درصد به ۱۴ درصد، Normalized Exact Match از ۵ درصد به ۱۴ درصد، Levenshtein Similarity از ۰٫۴۸۰ به ۰٫۶۰۲ و Word F1 از ۰٫۳۴۰ به ۰٫۴۴۶ افزایش یافت. همچنین خروجی مدل در ۱۳۱ نمونه از ۲۰۰ نمونه از نظر Levenshtein Similarity بهتر شد.

نتایج نشان می‌دهند فاین‌تیون QLoRA توانایی مدل را در استخراج عنوان فارسی افزایش داده است. بااین‌حال، مقدار Exact Match نهایی نشان می‌دهد تشخیص عناوین چندخطی، خواندن فونت‌های دشوار و حذف نوشته‌های غیرمرتبط همچنان به داده و تنظیمات بیشتر نیاز دارد. در مجموع، هدف

اصلی پروژه یعنی بهبود عملکرد مدل پس از فاین‌تیون و مقایسه کمّی نتایج قبل و بعد از آموزش محقق شد.

- کنترل متن جایگذاری‌شده
- کنترل شماره جدول‌ها
- آماده‌سازی فایل‌های تحویل